

BodyPoseRec

Technical Analysis Document Riconoscimento delle 7 Pose Obbligatorie del Bodybuilding Maschile

Progetto finale - Corso di Computer Vision - EPICODE Institute of Technology

Abstract

BodyPoseRec è un sistema di Computer Vision che riconosce le sette pose obbligatorie del bodybuilding maschile a partire dai keypoint scheletrici del corpo. La pipeline integra le quattro fasi richieste - acquisizione e preprocessing, feature engineering, classificazione (modello classico e deep learning), post-processing - e aggiunge moduli di pose scoring, interpretabilità (XAI) e analisi di robustezza. Per ragioni di privacy e riproducibilità il sistema è addestrato su un dataset sintetico di keypoint generato dai descrittori cinematici delle pose. Sul test set entrambi i modelli (SVM con kernel RBF e MLP a due strati nascosti) raggiungono accuratezza, precision, recall ed F1 macro pari a 1.000. Poiché i dati puliti sono separabili per costruzione, la failure analysis è condotta tramite stress test controllati: il sistema mantiene buona accuratezza fino a un rumore moderato sui keypoint e degrada in modo prevedibile sotto occlusione. La stabilizzazione temporale riduce il flickering delle predizioni di circa il 92%.

1. Problem Statement

Nelle competizioni di bodybuilding maschile la valutazione degli atleti si articola su sette pose obbligatorie codificate ("mandatory poses"): Front Double Biceps, Front Lat Spread, Side Chest, Side Triceps, Back Double Biceps, Back Lat Spread e Abdominals and Thighs. Ogni posa mette in evidenza specifici gruppi muscolari secondo una configurazione articolare precisa. Il riconoscimento di queste pose è attualmente affidato esclusivamente all'occhio di giudici esperti: un processo intrinsecamente soggettivo, non tracciabile e non scalabile.

Il problema affrontato da BodyPoseRec è la classificazione automatica della posa eseguita da un atleta a partire da un flusso video. La sua rilevanza è triplice. Sul piano applicativo, un sistema di questo tipo supporta l'allenamento (feedback immediato all'atleta), la preparazione di gara e l'analisi tecnica. Sul piano informatico, il problema è un caso di studio completo di classificazione di pose umane, che richiede l'intera pipeline di Computer Vision: stima dei keypoint, rappresentazione delle feature, modello di classificazione e post-processing. Sul piano della difficoltà, il dominio presenta sfide concrete: le pose laterali possono essere eseguite indifferentemente sul lato sinistro o destro (serve invarianza speculare); le pose di schiena occludono il volto; gli atleti hanno proporzioni antropometriche molto diverse.

2. Methodology

2.1 Architettura della pipeline

Il sistema è organizzato come una pipeline modulare a quattro stadi. (1) **Acquisizione e preprocessing**: generazione di scheletri sintetici a 33 landmark e relativa normalizzazione. (2) **Feature engineering**: trasformazione dei keypoint in un vettore di 26 feature geometriche. (3) **Classificazione**: due modelli distinti, un SVM (classico) e un MLP (deep learning). (4) **Post-processing**: stabilizzazione temporale delle predizioni tramite media mobile sulle probabilità. Moduli aggiuntivi realizzano il punteggio di qualità della posa, l'analisi di interpretabilità e l'analisi di robustezza.

2.2 Acquisizione dei dati: keypoint sintetici

Non esiste un dataset pubblico di pose di bodybuilding annotate, e l'uso di video reali di atleti solleverebbe problemi di privacy e di diritto d'autore. Il sistema e' quindi addestrato su un dataset sintetico: per ciascuna posa, partendo dai descrittori cinematici (angoli di spalla, gomito, anca, ginocchio; posizione di mani e piedi), viene costruito uno scheletro prototipo a 33 landmark nel formato MediaPipe BlazePose. Su ogni campione si applicano poi variazioni antropometriche (altezza, larghezza delle spalle, proporzioni degli arti), rumore articolare gaussiano e flip orizzontale. Sono generati 600 campioni per classe, 4200 in totale, perfettamente bilanciati. La generazione sintetica e' la stessa tecnica usata negli script di laboratorio del Modulo 3 quando un dataset reale non e' disponibile, ed e' citata esplicitamente nella sezione di Ethical Considerations come scelta consapevole.

2.3 Feature engineering

I keypoint grezzi non vengono passati direttamente al classificatore. Lo scheletro viene prima normalizzato per ottenere invarianza alla traslazione (origine sul punto medio del bacino) e alla scala (divisione per l'altezza del torso). Da qui si estrae un vettore di 26 feature geometriche raggruppate in cinque famiglie: angoli articolari (gomito, abduzione di spalla, ginocchio, anca, inclinazione del tronco), distanze normalizzate (tra polsi, gomiti, caviglie; mano-anca), rapporti corporei (spalle/anche, apertura delle braccia, larghezza della base d'appoggio), descrittori di profondita' e orientamento (asse z dei landmark) e indicatori di visibilita'. Questo approccio - feature geometriche interpretabili invece dell'immagine grezza - e' coerente con il Modulo 2 ed e' robusto anche con un numero contenuto di campioni.

2.4 Modelli di classificazione

La traccia richiede sia un modello classico sia un modello deep learning. Il **modello classico** e' una Support Vector Machine con kernel RBF; gli iperparametri C e gamma sono selezionati con GridSearchCV (5-fold cross-validation), preceduta da standardizzazione delle feature. Il **modello deep learning** e' un Multi-Layer Perceptron implementato in Keras/TensorFlow, con architettura Input(26) - Dense(64, ReLU) - Dropout(0.3) - Dense(32, ReLU) - Dropout(0.3) - Dense(7, Softmax), ottimizzatore Adam e loss categorical cross-entropy. Il Dropout e l'early stopping sulla loss di validazione contrastano l'overfitting. I due modelli condividono le stesse feature, quindi il confronto e' equo.

2.5 Post-processing e moduli aggiuntivi

Nella pipeline real-time le predizioni vengono stabilizzate con una media mobile sui vettori di probabilita' softmax (finestra FIFO di 7 frame) seguita da una soglia di confidenza che marca come "incerte" le predizioni deboli. Il modulo di **pose scoring** confronta gli angoli dell'atleta con quelli di un prototipo di riferimento e assegna un punteggio di qualita' 0-100. Il modulo **XAI** stima l'importanza di ciascuna feature tramite permutation importance. Per la demo da webcam, l'estrazione dei keypoint e' delegata a MediaPipe Pose: un modello pre-addestrato usato come semplice estrattore di rappresentazione, in linea con la regola d'esame che ne consente l'uso se combinato con logica custom.

3. Experimental Results

3.1 Setup sperimentale

Il dataset di 4200 campioni e' suddiviso in modo stratificato in training (70%, 2940 campioni), validation (15%, 630) e test (15%, 630), con seed fisso per la riproducibilita'. Il validation set guida la scelta degli iperparametri e l'early stopping; il test set e' cieco e usato una sola volta per la valutazione finale. Le metriche adottate sono quelle indicate dalla traccia per i problemi di classificazione: accuracy, precision, recall, F1-score (in versione macro, ossia mediata sulle classi) e matrice di confusione; e' inoltre riportata l'AUC macro (curve ROC One-vs-Rest).

3.2 Risultati sul test set

La Tabella 1 confronta i due modelli sul test set cieco. Entrambi classificano correttamente tutti i 630 campioni.

Metrica	SVM (classico)	MLP (deep learning)
Accuracy	1.0000	1.0000
Macro Precision	1.0000	1.0000
Macro Recall	1.0000	1.0000
Macro F1-score	1.0000	1.0000
Macro AUC	1.0000	1.0000

Tabella 1 - Confronto SVM vs MLP sul test set (630 campioni, 90 per classe).

Le matrici di confusione (Figura 1) sono perfettamente diagonali: nessuna posa viene confusa con un'altra. Questo risultato, lungi dall'essere sospetto, e' la conseguenza diretta del fatto che il dataset sintetico e' separabile per costruzione - ogni posa ha una firma geometrica netta. Cio' rende necessaria una failure analysis basata su stress test, discussa nella Sezione 4.




Figura 1 - Matrici di confusione sul test set: SVM (sinistra) e MLP (destra).

3.3 Andamento dell'addestramento dell'MLP

L'MLP e' stato addestrato per un massimo di 120 epoche con early stopping (pazienza 15). L'addestramento si e' interrotto alla 84a epoca. La Figura 2 mostra le curve di loss e accuratezza: training e validation procedono insieme senza divergenze, segno che il Dropout e l'early stopping hanno efficacemente prevenuto l'overfitting.




Figura 2 - Curve di loss e accuratezza dell'MLP (training vs validation).

4. Failure Analysis

Su dati sintetici puliti il sistema non commette errori: una failure analysis basata solo sul test set sarebbe quindi vuota. Per analizzare in modo onesto i limiti del sistema, le condizioni operative reali sono state simulate degradando in modo controllato i keypoint del test set e misurando il decadimento delle prestazioni. Sono stati condotti tre stress test.

4.1 Stress test: rumore sui keypoint

A ogni landmark e' stato sommato rumore gaussiano di deviazione standard crescente, simulando l'imprecisione di MediaPipe in condizioni di scarsa illuminazione o bassa risoluzione. La Tabella 2 riporta i risultati.

Rumore (sigma)	Accuracy SVM	Accuracy MLP
0.00	1.000	1.000
0.02	0.995	0.997
0.03	0.935	0.971
0.05	0.687	0.824
0.07	0.456	0.644
0.10	0.235	0.470

Tabella 2 - Accuratezza al crescere del rumore sui keypoint.

Emerge un risultato chiave: l'MLP e' sistematicamente piu' robusto dell'SVM. Per rumore moderato (sigma fino a 0.03) entrambi i modelli restano sopra il 93% di accuratezza, ma all'aumentare del rumore il vantaggio dell'MLP cresce - a sigma 0.05 l'MLP ottiene 0.82 contro 0.69 dell'SVM. Questo motiva la scelta dell'MLP come modello predefinito nella demo real-time, dove il rumore di MediaPipe e' inevitabile.

4.2 Stress test: occlusione e profondita'

Nel secondo test un numero crescente di landmark e' stato "oscurato" (azzerandone la visibilita' e perturbandone la posizione), simulando arti nascosti dal corpo o usciti dall'inquadratura. Con un solo landmark occluso l'accuratezza scende a circa 0.93-0.95; con quattro landmark occlusi crolla a circa 0.60 per entrambi i modelli. Nel terzo test e' stata degradata la sola coordinata di profondita' (asse z): il sistema regge bene piccoli errori (a sigma_z 0.05 l'accuratezza resta sopra 0.98) ma peggiora sensibilmente oltre, indicando una dipendenza dalle feature di profondita' usate per distinguere le pose laterali. La Figura 3 riassume le tre curve di degrado.




Figura 3 - Curve di degrado: rumore, occlusione e perturbazione della profondita'.

4.3 Confusioni tipiche sotto stress

Analizzando gli errori dell'MLP sotto forte rumore (sigma 0.10) emergono confusioni non casuali ma *biomeccanicamente plausibili*. La confusione piu' frequente e' Back Lat Spread scambiata per Back Double Biceps: due pose di schiena che condividono l'orientamento del corpo e differiscono solo nella configurazione delle braccia, l'informazione piu' fragile sotto rumore. Analogamente Side Triceps viene confusa con

Abdominals and Thighs e Side Chest con Front Double Biceps. Il pattern conferma che il sistema, quando sbaglia, sbaglia "in modo ragionevole": perde il dettaglio fine degli arti ma conserva l'asse frontale/posteriore. La Figura 4 mostra la matrice di confusione sotto stress.




Figura 4 - Matrice di confusione dell'MLP sotto rumore elevato (sigma 0.10).

4.4 Interpretabilita' (XAI)

L'analisi di permutation importance spiega su quali feature il modello fa affidamento. La feature dominante e' di gran lunga la visibilita' del naso (nose_visibility): da sola distingue l'asse frontale da quello posteriore (nelle pose di schiena il volto e' occluso). Le altre feature mostrano importanza individuale ridotta: non perche' inutili, ma perche' *ridondanti* - il dataset e' talmente separabile che, permutando una singola feature, le altre compensano. Questa ridondanza e' essa stessa un risultato: spiega perche' i modelli sono cosi' robusti al rumore moderato e perche' le matrici di confusione pulite sono diagonali. La Figura 5 mostra il ranking di importanza per l'MLP.





Figura 5 - Permutation feature importance per l'MLP.

4.5 Stabilizzazione temporale

L'ultimo aspetto analizzato e' il comportamento temporale. Una routine di gara sintetica (180 frame, 4 pose) e' stata classificata frame per frame, con e senza media mobile. Senza stabilizzazione la predizione cambia etichetta 36 volte (contro le 3 transizioni reali): un flickering vistoso. Con la media mobile i cambi scendono a 3, una riduzione del 92%, e l'accuratezza frame-by-frame migliora da 0.89 a 0.96. La Figura 6 visualizza l'effetto.

BodyPoseRec - Effetto della stabilizzazione temporale sul flickering



4.6 Limiti del sistema

I principali limiti emersi sono tre. Primo: il sistema è addestrato su dati sintetici; la transizione a video reali richiederebbe una validazione su keypoint estratti da MediaPipe da filmati veri. Secondo: la robustezza all'occlusione è limitata - oltre due o tre landmark mancanti le prestazioni calano sensibilmente. Terzo: il sistema classifica pose statiche, non gestisce esplicitamente le transizioni tra una posa e l'altra, che vengono assorbite solo dal filtro temporale.

5. Ethical Considerations

5.1 Privacy e dati biometrici

La posa e la conformazione del corpo sono dati biometrici sensibili. Un sistema addestrato su video reali di atleti ricadrebbe nel campo del GDPR (in Europa) e di normative come il BIPA (in alcuni stati USA), che impongono consenso esplicito e limitazioni sulla conservazione. BodyPoseRec affronta il problema alla radice: il dataset è interamente sintetico, quindi nessuna persona reale è coinvolta nell'addestramento. Nella demo live, inoltre, l'elaborazione avviene interamente in locale (edge processing): il sistema lavora sui soli keypoint e non salva né trasmette i frame della webcam, secondo il principio del data minimization.

5.2 Bias di rappresentazione

Un dataset sintetico elimina i problemi di privacy ma introduce un rischio diverso: il bias del generatore. I prototipi delle pose codificano un certo intervallo di proporzioni antropometriche; se tale intervallo non copre la reale diversità degli atleti (per altezza, struttura, età), il modello potrebbe risultare meno accurato su corporature fuori distribuzione. La variazione antropometrica inserita nel generatore mitiga in parte il problema, ma non lo elimina. È inoltre importante notare che il progetto riguarda esplicitamente le pose del bodybuilding *maschile*: il sistema non va usato su categorie diverse (Women's Physique, Figure) senza un riaddestramento dedicato, perché la tassonomia delle pose è differente.

5.3 Uso responsabile

BodyPoseRec è uno strumento di supporto, non un giudice automatico. Il punteggio di qualità della posa è calcolato rispetto a un prototipo geometrico e non sostituisce la valutazione di un giudice umano, che considera anche definizione muscolare, simmetria e presenza scenica - aspetti fuori dalla portata di un classificatore basato su soli keypoint. Presentare il punteggio come verdetto oggettivo sarebbe fuorviante: va comunicato come feedback indicativo. Il sistema rispetta inoltre le buone pratiche di sicurezza viste nel corso: nessuna dipendenza da servizi esterni in fase di inferenza, codice ispezionabile e modelli interpretabili tramite l'analisi XAI.

6. Conclusion and Future Work

BodyPoseRec realizza una pipeline di Computer Vision completa e modulare per il riconoscimento delle sette pose obbligatorie del bodybuilding maschile, soddisfacendo tutti i requisiti della traccia: le quattro fasi della pipeline, un modello classico e uno deep learning, una valutazione quantitativa con le metriche appropriate, una failure analysis basata su stress test e un'analisi etica. I due modelli raggiungono prestazioni perfette su dati puliti; la robustezza analizzata sotto degrado mostra che l'MLP è la scelta migliore per l'uso real-time, e che la stabilizzazione temporale è essenziale per una predizione stabile.

Gli sviluppi futuri naturali sono tre. Primo, la validazione su un dataset reale di keypoint estratti da video di gara, per misurare il divario tra dominio sintetico e reale. Secondo, l'introduzione di un modello temporale esplicito (LSTM o GRU) che classifichi le *sequenze* di pose di un'intera routine invece dei singoli frame. Terzo, l'estensione ad altre categorie competitive con la loro tassonomia di pose. La struttura modulare del progetto

rende ciascuna estensione realizzabile senza riscrivere la pipeline.